

Proposed Method

基于 BIC 正则化似然比锚点选择的锚点图多视图聚类

目录

1	问题定义	3
2	方法总体框架	3
3	符号定义	4
4	BIC 正则化似然比锚点选择	5
4.1	节点统计量与平方误差	5
4.2	原假设与备择假设	6
4.3	单簇模型的极大似然	6
4.4	双簇共享方差模型的极大似然	7
4.5	似然比统计量与 BIC 证据校准	7
4.6	候选切分的确定性扫描	8
4.7	视图级 BIC 证据与基准视图选择	8
5	多视图锚图学习目标	9
6	优化变量更新推导	10
6.1	更新视图基矩阵：最小二乘与正交 Procrustes	10
6.2	更新锚图矩阵：概率单纯形投影	11
6.3	概率单纯形投影的 KKT 推导	12
7	跨视图锚点对齐	12
7.1	锚点结构图与跨视图相似矩阵	12
7.2	投影固定点匹配目标	13
7.3	相似度加权映射	14

目录	2
8 等权融合与聚类	14
8.1 融合锚图	14
8.2 奇异向量嵌入与 KMeans	15
9 完整算法	16
10 收敛性与停止准则	17
11 复杂度分析	17
11.1 BIC-LR 锚点选择复杂度	17
11.2 视图内锚图优化复杂度	17
11.3 跨视图对齐与聚类复杂度	18
12 方法特点与边界	18

1 问题定义

设共有 n 个待聚类样本、 V 个视图以及 c 个聚类。第 v 个视图的原始数据矩阵记为

$$X_{\text{raw}}^{(v)} \in \mathbb{R}^{n \times d_v}, \quad v = 1, \dots, V, \quad (1)$$

其中每一行对应一个样本，每一列对应该视图下的一个特征维度。在锚图优化阶段，为了与矩阵分解形式一致，采用列表示样本：

$$\tilde{X}^{(v)} = \mathcal{N}((X_{\text{raw}}^{(v)})^T) \in \mathbb{R}^{d_v \times n}, \quad (2)$$

其中 $\mathcal{N}(\cdot)$ 表示逐维标准化处理。后续记 $\tilde{x}_i^{(v)} \in \mathbb{R}^{d_v}$ 为第 v 个视图中第 i 个样本的列向量。

多视图聚类的目标是在不使用类别标签参与模型求解的条件下，学习每个样本的聚类标记

$$\hat{y}_i \in \{1, \dots, c\}, \quad i = 1, \dots, n. \quad (3)$$

标签只用于确定评价时的类别数以及计算聚类指标，不进入锚点选择、锚图学习或跨视图对齐的优化目标。

2 方法总体框架

本文方法属于锚点图多视图聚类。核心思想是在每个视图内自适应生成一组锚点，学习样本到锚点的概率型关系图，再将各视图锚图对齐到统一锚点空间并融合。与固定锚点数或仅依赖距离阈值的锚点选择不同，本文在 3AMVC 框架下引入 BIC 正则化似然比检验，用统计证据判断候选节点是否应继续分裂，从而得到视图自适应的锚点数量和锚点位置。

对第 v 个视图，锚点选择阶段输出

$$\Theta^{(v)} = \begin{bmatrix} (\theta_1^{(v)})^T \\ \dots \\ (\theta_{m_v}^{(v)})^T \end{bmatrix} \in \mathbb{R}^{m_v \times d_v}, \quad (4)$$

其中 m_v 是该视图自适应生成的锚点数。主优化阶段令

$$A^{(v)} \in \mathbb{R}^{d_v \times m_v} \quad (5)$$

表示由锚点初始化并迭代更新的视图基矩阵，令

$$Z^{(v)} \in \mathbb{R}^{m_v \times n} \quad (6)$$

表示第 v 个视图的锚图。矩阵 $Z^{(v)}$ 的第 j 列 $z_j^{(v)}$ 绑定第 j 个样本，列中第 k 个元素表示该样本与第 k 个锚点之间的关系强度。因此每一列是样本到锚点的概率分配，满足

$$z_j^{(v)} \geq 0, \quad \mathbf{1}^\top z_j^{(v)} = 1. \quad (7)$$

在列样本方向下，视图内锚图学习可写为

$$\tilde{X}^{(v)} \approx A^{(v)} Z^{(v)}. \quad (8)$$

若采用行样本方向并令 $\bar{Z}^{(v)} = (Z^{(v)})^\top \in \mathbb{R}^{n \times m_v}$ 、 $\bar{A}^{(v)} = (A^{(v)})^\top \in \mathbb{R}^{m_v \times d_v}$ ，则等价表示为

$$X_{\text{raw}}^{(v)} \approx \bar{Z}^{(v)} \bar{A}^{(v)}, \quad (9)$$

这解释了常见的 $X \approx ZA$ 写法：每个样本由锚点基向量的凸组合近似重构。

不同视图可以选择不同数量和位置的锚点，且锚点索引并不天然一一对应。对于任意非基准视图，需要学习其锚点到基准视图锚点的匹配关系。若交换某一视图锚点顺序，则锚图的行也相应置换；因此跨视图对齐本质上是在锚点索引空间中学习置换或多对一映射。本文先利用锚点结构一致性得到硬匹配，再利用锚图关系向量的余弦相似度对匹配边赋权，最后采用等权平均融合所有对齐后的锚图。

3 符号定义

表 1: 主要数学符号及含义。

符号	维度	含义
n	标量	样本数
V	标量	视图数
c	标量	聚类类别数
d_v	标量	第 v 个视图的特征维度
$X_{\text{raw}}^{(v)}$	$n \times d_v$	第 v 个视图的原始数据矩阵
$\tilde{X}^{(v)}$	$d_v \times n$	转置并标准化后的第 v 个视图数据矩阵
$\Theta^{(v)}$	$m_v \times d_v$	第 v 个视图的锚点中心矩阵
m_v	标量	第 v 个视图的锚点数
$A^{(v)}$	$d_v \times m_v$	第 v 个视图的锚点基矩阵或投影矩阵
$Z^{(v)}$	$m_v \times n$	第 v 个视图的样本-锚点概率锚图
$z_j^{(v)}$	$m_v \times 1$	第 j 个样本在第 v 个视图中的锚点分配向量
β	标量	锚图 Frobenius 正则项系数
λ	标量	跨视图锚点结构对齐项权重

符号	维度	含义
λ_{BIC}	标量	BIC 惩罚系数
$n_{\min}$	标量	候选子节点的最小样本数约束
τ	标量	接受分裂的似然比得分阈值
ε	标量	方差和归一化中的数值保护常数
G_b, G_i	$m_b \times m_b,$ $m_i \times m_i$	基准视图与第 i 个视图的锚点结构图
K_{bi}	$m_b \times m_i$	基准视图与第 i 个视图之间的锚点关系相似矩阵
P_i	$m_b \times m_i$	第 i 个视图到基准视图的硬匹配矩阵
T_i	$m_b \times m_i$	第 i 个视图到基准视图的相似度加权映射矩阵
S	$m_b \times n$	融合后的统一锚图
U	$n \times r$	由融合锚图提取的样本嵌入, $r = \min(n, m_b)$
$\hat{y}$	$n \times 1$	最终聚类标签

4 BIC 正则化似然比锚点选择

4.1 节点统计量与平方误差

对任一待判断节点 $C = \{x_1, \dots, x_{n_C}\} \subset \mathbb{R}^d$, 其均值为

$$\mu_C = \frac{1}{n_C} \sum_{i=1}^{n_C} x_i. \quad (10)$$

节点内平方误差定义为

$$W(C) = \sum_{i=1}^{n_C} \|x_i - \mu_C\|_2^2. \quad (11)$$

为了避免逐样本重复计算均值距离, 可将其展开为

$$\begin{aligned}
W(C) &= \sum_{i=1}^{n_C} (x_i^\top x_i - 2x_i^\top \mu_C + \mu_C^\top \mu_C) \\
&= \sum_{i=1}^{n_C} x_i^\top x_i - 2\mu_C^\top \sum_{i=1}^{n_C} x_i + n_C \mu_C^\top \mu_C \\
&= \sum_{i=1}^{n_C} x_i^\top x_i - \frac{1}{n_C} \left\| \sum_{i=1}^{n_C} x_i \right\|_2^2.
\end{aligned} \quad (12)$$

实现中采用式 (12) 计算节点 SSE, 并将理论上非负的结果截断到非负范围, 以消除浮点误差带来的微小负值。

4.2 原假设与备择假设

对当前节点 C ，需要判断其是否还应继续分裂。本文采用局部二模型检验：

$$H_0 : C \text{ 由一个球形高斯分布解释, 无需继续分裂,} \quad (13)$$

$$H_1 : C \text{ 可由两个共享方差的球形高斯子分布解释.} \quad (14)$$

其中 H_0 对应当前节点作为一个锚点叶节点； H_1 对应将当前节点拆分为两个子节点，并继续递归判断。

4.3 单簇模型的极大似然

在 H_0 下，假设

$$x_i \sim \mathcal{N}(\mu_0, \sigma_0^2 I_d), \quad i = 1, \dots, n_C. \quad (15)$$

似然函数为

$$L_0(C) = \prod_{i=1}^{n_C} (2\pi\sigma_0^2)^{-d/2} \exp\left(-\frac{\|x_i - \mu_0\|_2^2}{2\sigma_0^2}\right). \quad (16)$$

取对数得

$$\log L_0(C) = -\frac{n_C d}{2} \log(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum_{i=1}^{n_C} \|x_i - \mu_0\|_2^2. \quad (17)$$

对 μ_0 求导：

$$\frac{\partial}{\partial \mu_0} \sum_i \|x_i - \mu_0\|_2^2 = 2n_C \mu_0 - 2 \sum_i x_i. \quad (18)$$

令导数为零可得极大似然估计

$$\hat{\mu}_0 = \frac{1}{n_C} \sum_i x_i. \quad (19)$$

进一步对 σ_0^2 求导：

$$\frac{\partial \log L_0}{\partial \sigma_0^2} = -\frac{n_C d}{2\sigma_0^2} + \frac{W_0}{2(\sigma_0^2)^2}, \quad (20)$$

其中 $W_0 = W(C)$ 。令其为零得到

$$\hat{\sigma}_0^2 = \frac{W_0}{n_C d}. \quad (21)$$

考虑数值稳定性，实际采用

$$\sigma_0^2 = \frac{W_0}{n_C d} + \varepsilon. \quad (22)$$

代回对数似然，得到

$$\log L_0(C) = -\frac{n_C d}{2} [\log(2\pi\sigma_0^2) + 1]. \quad (23)$$

4.4 双簇共享方差模型的极大似然

对候选划分 $C = C_1 \cup C_2$, 令

$$n_1 = |C_1|, \quad n_2 = |C_2|, \quad n_C = n_1 + n_2,$$

并定义混合比例

$$\pi_1 = \frac{n_1}{n_C}, \quad \pi_2 = \frac{n_2}{n_C}. \quad (24)$$

在 H_1 下, 两个子节点服从共享球形方差的高斯模型:

$$x \in C_k \sim \mathcal{N}(\mu_k, \sigma_{12}^2 I_d), \quad k = 1, 2. \quad (25)$$

条件于候选划分, 完整对数似然为

$$\begin{aligned} \log L_1(C_1, C_2) &= \sum_{k=1}^2 \sum_{x_i \in C_k} \log \left[\pi_k (2\pi\sigma_{12}^2)^{-d/2} \exp \left(-\frac{\|x_i - \mu_k\|_2^2}{2\sigma_{12}^2} \right) \right] \\ &= n_1 \log \pi_1 + n_2 \log \pi_2 - \frac{n_C d}{2} \log(2\pi\sigma_{12}^2) - \frac{W_1 + W_2}{2\sigma_{12}^2}, \end{aligned} \quad (26)$$

其中 $W_k = W(C_k)$ 。类似单簇情形, 均值的极大似然估计是各子节点样本均值, 共享方差估计为

$$\sigma_{12}^2 = \frac{W_1 + W_2}{n_C d} + \varepsilon. \quad (27)$$

于是

$$\log L_1(C_1, C_2) = n_1 \log \pi_1 + n_2 \log \pi_2 - \frac{n_C d}{2} [\log(2\pi\sigma_{12}^2) + 1]. \quad (28)$$

全文均采用共享方差假设; 即两个子分布拥有不同均值, 但使用同一个球形方差 σ_{12}^2 。

4.5 似然比统计量与 BIC 证据校准

不加复杂度校正时, 局部似然比统计量为

$$\Lambda(C_1, C_2) = 2 [\log L_1(C_1, C_2) - \log L_0(C)]. \quad (29)$$

双簇模型通常具有更强拟合能力, 若只依据 Λ 判断, 容易产生过度分裂。因此引入 BIC 型惩罚, 定义正则化切分得分:

$$\mathcal{S}(C_1, C_2) = 2 [\log L_1(C_1, C_2) - \log L_0(C)] - \lambda_{\text{BIC}}(d+1) \log n_C. \quad (30)$$

其中 $\lambda_{\text{BIC}} \geq 0$ 控制惩罚强度。惩罚项的作用是抵消双簇模型由于新增参数带来的自然拟合优势: 维度 d 对应新增均值自由度量级, 额外常数项对应方差或模型复杂度增量的校准。该项越大, 接受分裂越保守, 生成锚点通常越少。

对所有候选切分, 选择

$$(C_1^*, C_2^*) = \arg \max_{(C_1, C_2) \in \mathcal{P}(C)} \mathcal{S}(C_1, C_2), \quad (31)$$

其中 $\mathcal{P}(C)$ 是满足最小子节点规模约束的候选集合。若

$$\mathcal{S}(C_1^*, C_2^*) > \tau, \quad (32)$$

则接受分裂；否则将当前节点作为叶节点。默认 $\tau = 0$ ，表示只有当 BIC 校准后的似然证据为正时才继续分裂。

4.6 候选切分的确定性扫描

直接枚举所有二分组合不可行。因此本文采用确定性的一维候选生成策略。首先对当前节点样本中心化：

$$\bar{X}_C = X_C - \mathbf{1}\mu_C^\top. \quad (33)$$

对 $\bar{X}_C$ 做经济型奇异值分解：

$$\bar{X}_C = U_C \Sigma_C V_C^\top. \quad (34)$$

取第一主方向 v_1 ，将样本投影为

$$p_i = (x_i - \mu_C)^\top v_1. \quad (35)$$

随后按 p_i 升序排序，并扫描满足

$$n_{\min} \leq t \leq n_C - n_{\min} \quad (36)$$

的切分位置。最小节点规模 $n_{\min}$ 的作用是避免极小子节点造成不稳定似然估计或过细锚点划分。它是工程和统计稳定性约束，不单独构成理论创新。

投影方向只用于生成候选切分顺序，式 (23)、(28) 和 (30) 中的 SSE 与似然均在原始 d 维特征空间中计算。为了加速扫描，排序后构造前缀和与前缀平方和。对左侧前 t 个样本：

$$W_L(t) = \sum_{i=1}^t x_i^\top x_i - \frac{1}{t} \left\| \sum_{i=1}^t x_i \right\|_2^2, \quad (37)$$

右侧同理：

$$W_R(t) = \sum_{i=t+1}^{n_C} x_i^\top x_i - \frac{1}{n_C - t} \left\| \sum_{i=t+1}^{n_C} x_i \right\|_2^2. \quad (38)$$

由此每个候选切分可以用前缀统计量快速得到 W_1, W_2 ，避免在扫描过程中反复计算均值。

4.7 视图级 BIC 证据与基准视图选择

某一视图完成递归分裂后，得到 m_v 个叶节点。第 k 个叶节点的锚点为

$$\theta_k^{(v)} = \frac{1}{|C_k^{(v)}|} \sum_{x_i \in C_k^{(v)}} x_i. \quad (39)$$

设该视图最终划分的总 SSE 为

$$W_{\text{part}}^{(v)} = \sum_{k=1}^{m_v} W(C_k^{(v)}), \quad (40)$$

混合比例为

$$\pi_k^{(v)} = \frac{|C_k^{(v)}|}{n}. \quad (41)$$

将最终划分视为 m_v 分量共享方差球形高斯模型，其对数似然为

$$\log L_{\text{part}}^{(v)} = \sum_{k=1}^{m_v} |C_k^{(v)}| \log \pi_k^{(v)} - \frac{nd_v}{2} [\log(2\pi\sigma_{\text{part}}^2) + 1], \quad (42)$$

其中

$$\sigma_{\text{part}}^2 = \frac{W_{\text{part}}^{(v)}}{nd_v} + \varepsilon. \quad (43)$$

与整视图单簇模型相比，定义 BIC 证据增益

$$\Delta_{\text{BIC}}^{(v)} = 2 \left[\log L_{\text{part}}^{(v)} - \log L_0^{(v)} \right] - \lambda_{\text{BIC}}(m_v - 1)(d_v + 1) \log n. \quad (44)$$

进一步归一化为单位证据增益

$$q^{(v)} = \frac{\Delta_{\text{BIC}}^{(v)}}{2nd_v}. \quad (45)$$

本文以

$$b = \arg \max_{v \in \{1, \dots, V\}} q^{(v)} \quad (46)$$

选择基准视图。该选择表示：相对于单簇解释，基准视图的锚点划分在单位观测自由度上提供了最大的 BIC 校准证据。需要强调的是， $q^{(v)}$ 仅用于基准视图选择，最终融合仍采用等权平均。

5 多视图锚图学习目标

在每个视图中，给定锚点初始化后，学习 $A^{(v)}$ 与 $Z^{(v)}$ 。根据实现中的目标函数轨迹，可反推出主优化目标：

$$\min_{\{A^{(v)}, Z^{(v)}\}_{v=1}^V} \sum_{v=1}^V \left\| \tilde{X}^{(v)} - A^{(v)} Z^{(v)} \right\|_F^2 + \beta \sum_{v=1}^V \left\| Z^{(v)} \right\|_F^2, \quad (47)$$

满足

$$Z_{\cdot j}^{(v)} \geq 0, \quad \mathbf{1}^\top Z_{\cdot j}^{(v)} = 1, \quad j = 1, \dots, n. \quad (48)$$

第一项衡量每个视图中由锚点基矩阵和锚图重构样本的误差；第二项抑制锚图幅度，避免过大的锚点响应。 β 越大，对 $Z^{(v)}$ 的收缩越强。

Frobenius 范数满足

$$\|M\|_F^2 = \text{Tr}(M^\top M). \quad (49)$$

因此单视图重构项展开为

$$\begin{aligned} \|\tilde{X} - AZ\|_F^2 &= \text{Tr}[(\tilde{X} - AZ)^\top (\tilde{X} - AZ)] \\ &= \text{Tr}(\tilde{X}^\top \tilde{X}) - 2\text{Tr}(Z^\top A^\top \tilde{X}) + \text{Tr}(Z^\top A^\top AZ). \end{aligned} \quad (50)$$

式 (50) 是后续变量更新的基础。

6 优化变量更新推导

6.1 更新视图基矩阵：最小二乘与正交 Procrustes

固定 Z 后，单视图子问题为

$$\min_A \|\tilde{X} - AZ\|_F^2. \quad (51)$$

省略视图上标。由式 (50) 对 A 求导：

$$\frac{\partial}{\partial A} \|\tilde{X} - AZ\|_F^2 = 2(AZZ^\top - \tilde{X}Z^\top). \quad (52)$$

令导数为零得到正规方程

$$AZZ^\top = \tilde{X}Z^\top. \quad (53)$$

若不施加正交约束，则最小二乘解为

$$A^* = \tilde{X}Z^\top (ZZ^\top)^\dagger, \quad (54)$$

其中 $(\cdot)^\dagger$ 为 Moore-Penrose 广义逆。该形式用于处理 $d_v < m_v$ 或 $ZZ^\top$ 条件不佳的情形。

当 $d_v \geq m_v$ 时，可以对 A 施加列正交约束

$$A^\top A = I_{m_v}. \quad (55)$$

此时

$$\text{Tr}(Z^\top A^\top AZ) = \text{Tr}(Z^\top Z) \quad (56)$$

与 A 无关。因此式 (51) 等价于

$$\max_{A^\top A = I} \text{Tr}(A^\top \tilde{X}Z^\top). \quad (57)$$

令

$$C = \tilde{X}Z^\top, \quad C = U_C \Sigma_C V_C^\top \quad (58)$$

为经济型奇异值分解，则正交 Procrustes 解为

$$A^* = U_C V_C^T. \quad (59)$$

推导如下：

$$\begin{aligned} \text{Tr}(A^T C) &= \text{Tr}(A^T U_C \Sigma_C V_C^T) \\ &= \text{Tr}(V_C^T A^T U_C \Sigma_C). \end{aligned} \quad (60)$$

记 $Q = V_C^T A^T U_C$ 。在 $A^T A = I$ 下， Q 的奇异值不超过 1，因此

$$\text{Tr}(Q \Sigma_C) \leq \sum_j \sigma_j(C), \quad (61)$$

当 $Q = I$ 时取等号，对应 $A = U_C V_C^T$ 。

6.2 更新锚图矩阵：概率单纯形投影

固定 A 后，单视图子问题为

$$\min_Z \|\tilde{X} - AZ\|_F^2 + \beta \|Z\|_F^2, \quad Z_j \in \Delta, \quad j = 1, \dots, n, \quad (62)$$

其中

$$\Delta = \{z \in \mathbb{R}^{m_v} \mid z \geq 0, \mathbf{1}^T z = 1\}. \quad (63)$$

若采用正交分支 $A^T A = I$ ，则对第 j 个样本有

$$\begin{aligned} \|\tilde{x}_j - Az_j\|_2^2 + \beta \|z_j\|_2^2 &= \tilde{x}_j^T \tilde{x}_j - 2z_j^T A^T \tilde{x}_j + z_j^T A^T A z_j + \beta z_j^T z_j \\ &= \tilde{x}_j^T \tilde{x}_j - 2z_j^T A^T \tilde{x}_j + (1 + \beta) z_j^T z_j. \end{aligned} \quad (64)$$

去掉常数项后，

$$\min_{z_j \in \Delta} (1 + \beta) \|z_j\|_2^2 - 2z_j^T A^T \tilde{x}_j. \quad (65)$$

配方可得

$$\begin{aligned} (1 + \beta) \|z_j\|_2^2 - 2z_j^T A^T \tilde{x}_j \\ = (1 + \beta) \left\| z_j - \frac{A^T \tilde{x}_j}{1 + \beta} \right\|_2^2 + \text{const}. \end{aligned} \quad (66)$$

因此

$$z_j^* = \Pi_\Delta \left(\frac{A^T \tilde{x}_j}{1 + \beta} \right), \quad (67)$$

其中 Π_Δ 表示投影到概率单纯形。

需要注意的是，当采用广义逆最小二乘分支更新 A 时， $A^T A = I$ 不一定严格成立。严格的二次子问题应为

$$\min_{z_j \in \Delta} z_j^T (A^T A + \beta I) z_j - 2z_j^T A^T \tilde{x}_j. \quad (68)$$

然而实际求解仍采用式 (67) 的投影形式。因此，式 (67) 是与正交分支严格一致、并被整体实现沿用的锚图更新。

6.3 概率单纯形投影的 KKT 推导

对任意向量 $v \in \mathbb{R}^m$, 单纯形投影求解

$$\min_x \frac{1}{2} \|x - v\|_2^2, \quad x \geq 0, \quad \mathbf{1}^\top x = k. \quad (69)$$

默认 $k = 1$ 。构造拉格朗日函数

$$\mathcal{L}(x, \lambda, \eta) = \frac{1}{2} \|x - v\|_2^2 \lambda (\mathbf{1}^\top x - k) - \eta^\top x, \quad \eta_i \geq 0. \quad (70)$$

KKT 条件为

$$x_i - v_i + \lambda - \eta_i = 0, \quad (71)$$

$$\eta_i x_i = 0, \quad (72)$$

$$x_i \geq 0, \quad \eta_i \geq 0. \quad (73)$$

当 $x_i > 0$ 时, $\eta_i = 0$, 于是 $x_i = v_i - \lambda$; 当 $x_i = 0$ 时, 有 $v_i - \lambda \leq 0$ 。因此最优解具有截断形式

$$x_i = \max(v_i - \lambda, 0). \quad (74)$$

标量 λ 由等式约束确定:

$$\sum_{i=1}^m \max(v_i - \lambda, 0) = k. \quad (75)$$

实现中先将输入平移为一个和为 k 的向量

$$v_0 = v - \bar{v} \mathbf{1} + \frac{k}{m} \mathbf{1}. \quad (76)$$

若 $v_0 \geq 0$, 则 v_0 已在单纯形上; 否则通过 Newton 迭代求解上述 λ , 并返回 $\max(v_0 - \lambda, 0)$ 。

7 跨视图锚点对齐

7.1 锚点结构图与跨视图相似矩阵

设 b 为基准视图, $i \neq b$ 为任一待对齐视图。由锚图构造锚点结构图:

$$G_b = Z^{(b)}(Z^{(b)})^\top \in \mathbb{R}^{m_b \times m_b}, \quad G_i = Z^{(i)}(Z^{(i)})^\top \in \mathbb{R}^{m_i \times m_i}. \quad (77)$$

矩阵 G_b 的第 (p, q) 个元素衡量基准视图中第 p 与第 q 个锚点在所有样本上的关系相似性; G_i 同理。跨视图锚点关系相似矩阵为

$$K_{bi} = Z^{(b)}(Z^{(i)})^\top \in \mathbb{R}^{m_b \times m_i}. \quad (78)$$

其第 (p, q) 个元素是基准视图第 p 个锚点关系向量与第 i 个视图第 q 个锚点关系向量的内积。

7.2 投影固定点匹配目标

对齐矩阵 $P_i \in \mathbb{R}^{m_b \times m_i}$ 通过以下目标学习:

$$\max_{P_i} f(P_i) = \langle K_{bi}, P_i \rangle \lambda \text{Tr}(G_b P_i G_i P_i^\top). \quad (79)$$

第一项

$$\langle K_{bi}, P_i \rangle = \sum_{p=1}^{m_b} \sum_{q=1}^{m_i} (K_{bi})_{pq} (P_i)_{pq} \quad (80)$$

鼓励匹配具有相似样本关系的锚点；第二项鼓励匹配后保持两视图锚点结构图的一致性。 λ 控制结构一致性项的强度。

对式 (79) 求梯度。线性项梯度为

$$\nabla_P \langle K, P \rangle = K. \quad (81)$$

结构项记作

$$h(P) = \text{Tr}(G_b P G_i P^\top).$$

其微分为

$$\begin{aligned} dh &= \text{Tr}(G_b dP G_i P^\top) + \text{Tr}(G_b P G_i dP^\top) \\ &= \text{Tr}((G_b^\top P G_i^\top)^\top dP) + \text{Tr}((G_b P G_i)^\top dP). \end{aligned} \quad (82)$$

由于 G_b 与 G_i 均为 $ZZ^\top$ 形式，是对称矩阵，因此

$$\nabla_P h(P) = 2G_b P G_i. \quad (83)$$

故总体梯度为

$$\nabla f(P) = K + 2\lambda G_b P G_i. \quad (84)$$

采用投影固定点迭代:

$$P^{(t+1)} = (1 - \alpha)P^{(t)} + \alpha \Gamma(\nabla f(P^{(t)})), \quad (85)$$

其中 $\alpha = 0.5$, $\Gamma(\cdot)$ 表示非负双随机约束的投影近似。为适配不同锚点数，梯度矩阵先被补为方阵，再执行固定轮数的行列归一化与非负截断。每次更新后还进行尺度归一化:

$$P^{(t+1)} \leftarrow \frac{P^{(t+1)}}{\max_{p,q} |P_{pq}^{(t+1)}|}, \quad (86)$$

用于避免数值尺度持续放大。

连续匹配矩阵收敛后，对每个非基准视图锚点 q 执行硬化:

$$p^*(q) = \arg \max_p P_{pq}, \quad (87)$$

$$(P_{\text{hard}})_{p^*(q),q} = 1, \quad (P_{\text{hard}})_{p,q} = 0 \quad (p \neq p^*(q)).$$

因此，每个非基准锚点被指派到一个基准锚点，而一个基准锚点可接收多个非基准锚点。

7.3 相似度加权映射

硬匹配只表示锚点对应关系，不反映匹配强弱。进一步计算锚图行向量的余弦相似度：

$$R_{pq} = \frac{(Z^{(b)})_{p\cdot} ((Z^{(i)})_{q\cdot})^\top}{\|(Z^{(b)})_{p\cdot}\|_2 \|(Z^{(i)})_{q\cdot}\|_2 + \varepsilon}. \quad (88)$$

取其非负部分 $R_{pq}^+ = \max(R_{pq}, 0)$ 作为边权来源。若第 p 个基准锚点对应的非基准锚点集合为 $\mathcal{N}(p)$ ，则在多对一情形下

$$(T_i)_{pq} = \frac{R_{pq}^+}{\sum_{q' \in \mathcal{N}(p)} R_{pq'}^+}, \quad q \in \mathcal{N}(p). \quad (89)$$

若非基准锚点数少于基准锚点数，则可能存在未覆盖的基准锚点。此时为未覆盖基准锚点补充最相似的非基准锚点，再对同一非基准锚点覆盖的基准集合 $\mathcal{B}(q)$ 做归一化：

$$(T_i)_{pq} = \frac{R_{pq}^+}{\sum_{p' \in \mathcal{B}(q)} R_{p'q}^+}, \quad p \in \mathcal{B}(q). \quad (90)$$

若归一化分母为零或出现非有限值，则使用均匀权重。由此得到非负加权映射矩阵 T_i ，并将第 i 个视图的锚图对齐到基准锚点空间：

$$\bar{Z}^{(i)} = T_i Z^{(i)} \in \mathbb{R}^{m_b \times n}. \quad (91)$$

对齐后每一列再次归一化，以保持非负且列和为 1。

8 等权融合与聚类

8.1 融合锚图

所有非基准视图对齐后，统一锚图采用等权平均：

$$S = \frac{1}{V} \left(Z^{(b)} + \sum_{i \neq b} \bar{Z}^{(i)} \right) = \frac{1}{V} \left(Z^{(b)} + \sum_{i \neq b} T_i Z^{(i)} \right). \quad (92)$$

随后对 S 的每一列执行非负化与归一化：

$$S_{\cdot j} \leftarrow \frac{\max(S_{\cdot j}, 0)}{\max(\mathbf{1}^\top \max(S_{\cdot j}, 0), \varepsilon)}. \quad (93)$$

若某列的和无效或过小，则将该列置为均匀分布。融合过程没有引入额外视图权重，所有视图在对齐后具有相同权重。

8.2 奇异向量嵌入与 KMeans

对融合锚图转置进行经济型奇异值分解:

$$S^T = U\Sigma V^T, \quad U \in \mathbb{R}^{n \times r}, \quad r = \min(n, m_b). \quad (94)$$

矩阵 U 作为样本嵌入。聚类前对其每一行进行归一化:

$$\bar{u}_i = \frac{u_i}{\max(\|u_i\|_2, \varepsilon)}. \quad (95)$$

随后在嵌入空间执行 KMeans:

$$\min_{\{\mathcal{C}_k\}_{k=1}^c, \{\mu_k\}_{k=1}^c} \sum_{k=1}^c \sum_{i \in \mathcal{C}_k} \|\bar{u}_i - \mu_k\|_2^2. \quad (96)$$

给定中心时, 标签分配为

$$\hat{y}_i = \arg \min_k \|\bar{u}_i - \mu_k\|_2^2; \quad (97)$$

给定标签时, 中心更新为

$$\mu_k = \frac{1}{|\mathcal{C}_k|} \sum_{i \in \mathcal{C}_k} \bar{u}_i. \quad (98)$$

若出现空簇, 则从当前距离较大的样本中补充缺失簇, 以保证聚类数不退化。

9 完整算法

Algorithm 1 BIC-LR 自适应锚点图多视图聚类

Require: 多视图数据 $\{X_{\text{raw}}^{(v)}\}_{v=1}^V$, 聚类数 c , 参数 $\beta, \lambda, \lambda_{\text{BIC}}, n_{\min}, \tau, \varepsilon$, 最大迭代次数 $T_{\max}$.

Ensure: 聚类标签 $\hat{y}$, 融合锚图 S , 样本嵌入 U .

```

1: for  $v = 1, \dots, V$  do
2:   在视图  $v$  上执行 BIC-LR 递归二分, 得到锚点  $\Theta^{(v)}$ 、叶节点 SSE 与样本-锚点
   标签。
3:   计算该视图的单位 BIC 证据增益  $q^{(v)}$ 。
4: end for
5: 选择基准视图  $b = \arg \max_v q^{(v)}$ 。
6: for  $v = 1, \dots, V$  do
7:   标准化数据得到  $\tilde{X}^{(v)}$ , 初始化  $A^{(v)} = (\Theta^{(v)})^\top$ 。
8:   令  $M^{(v)} = (A^{(v)})^\top \tilde{X}^{(v)}$ , 逐列投影到概率单纯形, 初始化  $Z^{(v)}$ 。
9: end for
10: for  $t = 1, \dots, T_{\max}$  do
11:   for  $v = 1, \dots, V$  do
12:     固定  $Z^{(v)}$ , 由式 (54) 或式 (59) 更新  $A^{(v)}$ 。
13:     固定  $A^{(v)}$ , 由式 (67) 逐列更新  $Z^{(v)}$ 。
14:   end for
15:   计算目标函数  $J^{(t)}$ 。
16:   if  $t > 9$  且相对目标变化小于阈值 then
17:     停止主优化。
18:     break
19:   end if
20: end for
21: for 每个  $i \neq b$  do
22:   构造  $G_b = Z^{(b)}(Z^{(b)})^\top$ 、 $G_i = Z^{(i)}(Z^{(i)})^\top$ 、 $K_{bi} = Z^{(b)}(Z^{(i)})^\top$ 。
23:   根据式 (85) 学习匹配矩阵, 并硬化为  $P_i$ 。
24:   根据余弦相似度构造加权映射  $T_i$ , 得到  $\bar{Z}^{(i)} = T_i Z^{(i)}$ 。
25: end for
26: 根据式 (92) 等权融合得到  $S$ , 并列归一化。
27: 对  $S^\top$  做 SVD, 得到样本嵌入  $U$ 。
28: 对  $U$  行归一化后执行 KMeans, 得到  $\hat{y}$ 。

```

10 收敛性与停止准则

该实现采用经验停止准则。主优化阶段记录

$$J^{(t)} = \sum_{v=1}^V \|\tilde{X}^{(v)} - A^{(v)} Z^{(v)}\|_F^2 + \beta \sum_{v=1}^V \|Z^{(v)}\|_F^2. \quad (99)$$

在至少执行若干轮迭代后，计算相邻目标的相对变化：

$$\rho^{(t)} = \left| \frac{J^{(t-1)} - J^{(t)}}{\max(|J^{(t-1)}|, \varepsilon)} \right|. \quad (100)$$

若

$$\rho^{(t)} < 10^{-6} \quad (101)$$

或目标值已经足够小，则停止主优化并进入对齐阶段。主循环还设有最大迭代次数。跨视图匹配阶段同样采用变量变化阈值：

$$\max_{p,q} |P_{pq}^{(t+1)} - P_{pq}^{(t)}| < 10^{-6}, \quad (102)$$

或达到最大匹配迭代次数即停止。本文不声称额外的理论收敛证明；上述准则是实现中的经验判据。

11 复杂度分析

以下复杂度根据主要矩阵运算估计。设主优化迭代次数为 T ，匹配迭代次数为 T_p ，KMeans 迭代次数为 T_k ，第 v 个视图的维度与锚点数分别为 d_v, m_v ，基准视图锚点数为 m_{b_0} 。

11.1 BIC-LR 锚点选择复杂度

对包含 s 个样本的节点，主要开销包括中心化和 SSE 计算 $O(sd_v)$ 、经济型 SVD 约 $O(sd_v \min(s, d_v))$ 、投影排序 $O(s \log s)$ ，以及前缀统计和候选扫描 $O(sd_v)$ 。整棵递归树的开销为所有节点代价之和：

$$O\left(\sum_C [|C|d_v \min(|C|, d_v) + |C| \log |C|]\right). \quad (103)$$

锚点安全上限限制了递归树规模。

11.2 视图内锚图优化复杂度

每次主迭代中，第 v 个视图主要包含：

- 计算 $\tilde{X}^{(v)}(Z^{(v)})^\top$: $O(d_v n m_v)$;
- 计算 $Z^{(v)}(Z^{(v)})^\top$: $O(m_v^2 n)$;
- 广义逆分支最坏约 $O(m_v^3)$;
- SVD Procrustes 分支约 $O(d_v m_v^2)$;
- 计算 $(A^{(v)})^\top \tilde{X}^{(v)}$: $O(d_v n m_v)$;
- n 个 m_v 维单纯形投影, 记投影平均迭代次数为 T_s , 约 $O(n m_v T_s)$ 。

因此主优化总复杂度可估计为

$$O\left(T \sum_{v=1}^V [d_v n m_v + m_v^2 n + m_v^3 + d_v m_v^2 + n m_v T_s]\right). \quad (104)$$

11.3 跨视图对齐与聚类复杂度

对非基准视图 i , 构造 K_{bi} 需要 $O(m_b m_i n)$, 构造 G_i 需要 $O(m_i^2 n)$ 。匹配迭代中计算 $G_b P G_i$ 的复杂度约为

$$O(m_b^2 m_i + m_b m_i^2). \quad (105)$$

投影近似在 $m_{\max} \times m_{\max}$ 方阵上执行固定轮数, 复杂度约为 $O(m_{\max}^2)$, 其中 $m_{\max} = \max(m_b, m_i)$ 。加权对齐 $T_i Z^{(i)}$ 需要 $O(m_b m_i n)$ 。

融合后, $S^\top \in \mathbb{R}^{n \times m_b}$ 的经济型 SVD 在 $n \geq m_b$ 时约为

$$O(n m_b^2). \quad (106)$$

KMeans 在 r 维嵌入上运行, 单次迭代复杂度约为 $O(n c r)$ 。若重复运行 R 次且每次内部重复 R_k 次, 评价阶段复杂度约为

$$O(R R_k T_k n c r). \quad (107)$$

12 方法特点与边界

本文方法的主要特点如下:

1. **自适应锚点选择**。每个视图通过 BIC 正则化似然比判断是否继续分裂, 使锚点数量由数据分布和统计证据共同决定。
2. **概率锚图表示**。每个样本到锚点的关系向量满足非负和列和为 1, 具有明确的分配含义。
3. **跨视图锚点对齐**。不同视图锚点数和索引可以不同, 因此通过锚点结构图和跨视图关系矩阵学习映射关系。
4. **结构保持匹配**。匹配目标同时考虑锚点关系向量相似性和锚点结构一致性。
5. **等权融合**。对齐后的锚图采用简单等权平均, 没有引入额外视图权重变量。
6. **奇异向量嵌入**。最终聚类基于融合锚图诱导的样本嵌入, 而不是直接在原始特征空间执行。

需要谨慎的是：当视图维度小于锚点数时，投影矩阵更新使用最小二乘形式而非正交 Procrustes 形式；此时锚图投影更新仍沿用正交情形下的简化公式。该分支应被理解为实现中的兼容处理。另一个需要确认的部分是相似度加权映射在论文叙述中的定位：它是当前实现的真实对齐步骤，但是否作为主要方法贡献，需要结合最终论文口径确定。